Detekcija i izračunavanje matematičkih izraza

Vladimir Inđić

Motivacija

matematičkih Računanje izraza koji su prikazani na slici ili papiru napisani na nije jednostavan proces. Zahteva ili manuelno računanje ili unošenje izraza u digitron. I jedan i drugi proces zahtevaju određeno vreme i podložni su greškama. Zar ne bi bilo lepo kada bismo samo mogli da slikamo izraz i dobijemo njegovo rešenje? Upravo to je motivacija za razvoj programa koji prepoznaje matematički izraz prikazan na slici i određuje njegov rezultat.

Konceptualno rešenje

Detekcija izraza prikazanog na slici zasniva se na dva osnovna principa:

- Obrada slike podrazumeva da se slika u boji prebaci u crno-belo (engl. *grayscale*), uklone nebitni detalji sa nje (engl. *threshold*), izdvoje konture koje sadrže karaktere, odradi *resize* izdvojene konture u sliku odgovarajuće veličine.
- Prepoznavanje karaktera
 tipičan problem koji može biti
 rešen upotrebom klasifikatora.
 U ovom programskom rešenju
 biće korišćene neuralna mreža
 (skraćeno NN) i konvolucijska
 neuralna mreža (skraćeno
 CNN).

Implementacija klasifkatora za detekciju matematičkih izraza

Dataset

- 160 slika dimenzija 32x32 napravljenih uz pomoć programa *Pages* i *OpenCV* biblioteke za kompjutersku viziju programskog jezika *Python*
- 16 klasa po jedna klasa za svaki karakter koji se može naći u izrazu:
 - cifre **0-9**,
 - operatori +, -, * i /,
 - male zagrade (,)
- Svaku klasu čini 10 slika istog karaktera prikazanog različitim fontom (Helvetica, Times, Arial, Times New Roman, PT Mono, America Typerwriter, Apple Chancery, Comic Sans MS, Verdana, Andale Mono)
- 80% slika za treniranje
- 20% slika za testiranje procesa treniranja







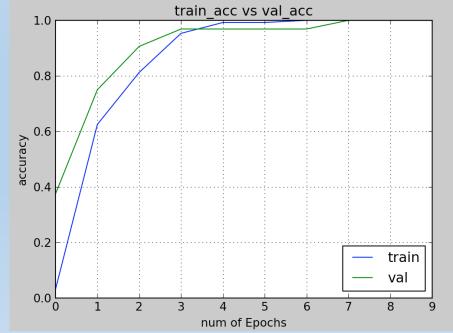




Slika 1. Nekoliko slika koje čine dataset

Neuralna mreža*

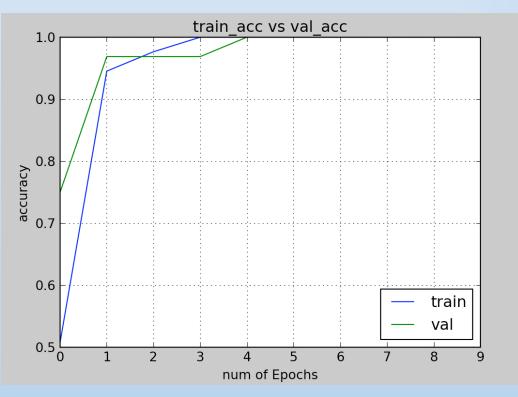
- Ulazni sloj od 1024 neurona
- Skriveni sloj od 1024 neurona
- Izlazni sloj od 16 neurona
- 10 epoha
- Uspesnošt treniranja 100%, postignuta u 8. epohi
- Vreme treniranja: 1,36s



Slika 2. Uspešnost *NN* tokom procesa treniranja

Konvolucijska neuralna mreža*

- Konvolucijski sloj (*Conv2D*): 32 filtera, veličina prozora 5x5
- *Pooling* sloj (*MaxPooling2D*): veličina prozora 2x2
- *Dropout* sloj zadužen za smanjenje overfittovanja (parametar *rate* postavljen na 0,2)
- Flatten sloj matricu prevodi u niz
- Potpuno povezani sloj od 256 neurona
- Izlazni sloj od 16 neurona
- 10 epoha
- Uspešnost treniranja 100%, postignuta u 5. iteraciji
- Vreme treniranja: 12,87s



Slika 3. Uspešnost *CNN* tokom procesa treniranja

Evaluacija klasifikatora

- 50 slika sa slučajno generisanim izrazima kojima je manuelno određena vrednost.
- Nekoliko novih fontova: Georgia, Arial Hebrew, Apple Braile, Helti SC, Apple SD Gothic Neo, Courier, Apple Gothic, Comic Sans MS
- Računanje vrednosti prepoznatog izraza pomoću *Pythonove eval* funkcije
- Uspešnost oba klasifikatora (NN i CNN) je 94-96%
- Greške ulgavnom na novim fontovima na kojima nije vršen proces treniranja (*Apple Gothic*, *Courier*)

Zaključak i dalja unapređenja programskog rešenja

Razvijeno programsko rešenje za izraza koristi detekciju klasifikatora. Oba su trenirana na relativno malom datasetu, ali i pored toga postižu zapažene rezultate. Očigledno da je za ovakav problem bolje koristiti NN umesto CNN. Prvenstveno zato što je vremenski period treniranja otprilike 10 puta manji. Treba uzeti u obzir i to da su slike dimenzija 32x32 jednostavne i da će se na malom datasetu CNN overfittovati, te ne može postići bolje rezultate od obične neuralne mreže za nove fontove.

Implementacija koncepta izloženog u ovom tekstu pokazala se kao veoma uspešna. Programsko rešenja bi se moglo unaprediti i za detekciju daleko većeg skupa izraza. Neophodno bi bilo uvesti veći broj fontova za treniranje klasifikatora, usložiti njihovu arhitekturu i uvesti pojedine algoritme za prepoznavanje redova u izrazu (recimo *KNN*), kako bi se mogli prepoznati i višelinijski izrazi.

*Implementirana korišćenjem *Pythonove* biblioteke *Keras*, koja je namenjena za *Deep Learning*.